



Universidad
Central

UNIVERSIDAD CENTRAL DE CHILE
FACULTAD DE INGENIERÍA Y ARQUITECTURA
ESCUELA DE INGENIERÍA
INGENIERÍA CIVIL EN COMPUTACIÓN E INFORMÁTICA

**DETECCIÓN DE RETINOPATÍA
DIABÉTICA POR MEDIO DEL
PROCESAMIENTO DE IMÁGENES
DE FONDOS DE RETINA A TRAVÉS
DE UN ALGORITMO DE RED
NEURONAL ARTIFICIAL
CONVOLUCIONAL**

MEMORIA PARA OPTAR AL TÍTULO DE: INGENIERO CIVIL EN
COMPUTACIÓN E INFORMÁTICA.

Profesor Guía: **Francisco Javier Cruz Naranjo**

Profesor Informante: **Hernan Alejandro Olmí Reyes**

Tomás Vicente Ortiz Figueroa

Santiago – Chile
2020



Universidad
Central

UNIVERSIDAD CENTRAL DE CHILE
FACULTAD DE INGENIERÍA Y ARQUITECTURA
ESCUELA DE INGENIERÍA
INGENIERÍA CIVIL EN COMPUTACIÓN E INFORMÁTICA

**DETECCIÓN DE RETINOPATÍA
DIABÉTICA POR MEDIO DEL
PROCESAMIENTO DE IMÁGENES
DE FONDOS DE RETINA A TRAVÉS
DE UN ALGORITMO DE RED
NEURONAL ARTIFICIAL
CONVOLUCIONAL**

MEMORIA PREPARADA BAJO LA SUPERVISIÓN DE LA COMISIÓN INTEGRADA POR LOS PROFESORES

Profesor Guía: **Francisco Javier Cruz Naranjo**

Profesores Informantes: **Hernan Alejandro Olmí Reyes**

QUIENES RECOMIENDAN QUE SEA ACEPTADA PARA COMPLETAR LAS EXIGENCIAS DEL TÍTULO DE INGENIERO CIVIL EN COMPUTACIÓN E INFORMÁTICA

Santiago – Chile
2020

Esta tesis está dedicada en gran parte a mi madre Sandra Figueroa Garin, persona que siempre me ha motivado y me ha permitido estudiar una gran carrera para mi opinión y gusto. Una persona quien siempre me tiene fe, independiente de mis errores, porque sabe que de ellos aprenderé y seré mejor persona, como mejor profesional. Esta tesis va dedicada a mi polola Camila Robles Salas, quien ha observado la mayor parte del proceso de investigación de este proyecto, y una de las personas que me sigue motivando, independiente del inmerso esfuerzo que es hacer una tesis, gracias a su amor incondicional. Una tercera dedicación va a mi profesor guía, el señor Francisco Cruz, quien ha tenido una gran consideración y atención en este proceso. Persona que le tengo un gran respeto y admiración, ya que ha tenido fe en mi, en mi manera de trabajar y en el gran proceso que ha sido estudiar, al menos desde que me conoce. Gran parte de esta memoria tiene sus correcciones, por no decir todas, pero con objetivo que yo entregue un gran trabajo. Por último y no menos importante, dedicar esta memoria a mis amigos y cercanos, quienes también han sido parte del proceso, al menos el inicial, mostrando interés del tema abordado, así como de mi trabajo. Sin más preambulo, mis más sinceros agradecimientos a toda persona parte de este proceso, quienes saben que yo aprecio de todo corazón cada alcance que me ha llegado. Espero que disfruten la lectura.

Tomás Vicente Ortiz Figueroa.

Agradecimientos

Para que la realización de esta memoria fuese posible, agradezco enormemente a mi amigo y compañero de carrera, Sebastián Hanania, quien siempre me motivó y ayudó a encontrar alguna solución, incluso en los peores momentos de la investigación, quién actuó como guía para mí, gracias Seba.

Agradecer también a mi profesor guía, el señor Francisco Cruz, un excelente y destacado investigador quien ha podido entregar su conocimiento hacia mí, con el fin de pulirme como estudiante y persona. Por lo que la mayoría de este documento tiene inmersas sus buenas prácticas de correcta escritura, así como investigativas, gracias profe.

Sin faltar mi polola Camila Robles y mi madre Sandra Angela Figueroa, quienes son mi apoyo espiritual para todo momento.

Resumen

Se propone la implementación de un algoritmo de Red Neuronal Convolucional o Convolutional Neural Network (CNN), aquella que posee como foco el procesamiento de imágenes de una manera práctica y eficiente, gracias a la propiedad de simetría (Mallat, 2016).

El algoritmo procesa una imagen de un fondo de retina, con el fin de que reconozca las estructuras de la capa posterior del globo ocular, permitiendo determinar si existe o no retinopatía diabética. Los médicos usan una prueba llamada “fondo de ojo”, técnica que permite observar el interior del globo ocular gracias a un instrumento llamado oftalmoscopio, con el fin de diagnosticar una enfermedad, o para comprobar la evolución de patologías.

La retinopatía diabética (RD), según la AAO (American Academy of Ophthalmology), es una enfermedad ocular que se presenta en personas con diabetes. Para pacientes de diabetes tipo 1, presentan o van a presentar cierto grado de RD durante su vida. Para pacientes del tipo 2 no todos llegan a desarrollar retinopatía diabética, sí lo va a presentar un porcentaje alto, pero no todos. Esta enfermedad causa daño a los vasos sanguíneos de la retina, dado los altos niveles de glucosa en la sangre hace que estas moléculas se acoplen unas a otras produciendo un impedimento en el flujo sanguíneo por lo que se secará el vaso para posteriormente hincharse y presentar fugas de líquido como puede ser plasma con grasas (lípidos), como hemorragias de sangre, afectando la visión del paciente.

Al algoritmo presente en esta investigación se le carga la imagen del examen médico a consultar, este lo modifica con las medidas estándar que posee como requisito la red neuronal artificial, luego es procesada la imagen por esta red, entrega un resultado basado en su aprendizaje por métodos de Deep y Transfer Learning. El resultado es la predicción de alguno de 5 grados o estados que posee esta enfermedad, o sea, un rango desde un paciente sano, hasta un paciente con retinopatía grado proliferativo, el cual es el de mayor estado de avance, probablemente un

paciente con ceguera.

Finalmente, el sistema desarrollado presenta una precisión de un 97,78 % para la predicción de retinopatía diabética presente en exámenes de fondos de ojo.

Palabras Clave: Diabetes, Retinopatía Diabética, Fondo de Ojo, Redes Neuronales Convolucionales.

Abstract

It is proposed the implementation of a Convolutional Neural Network (CNN) algorithm, which focuses on image processing in a practical and efficient way, thanks to the symmetry property (Mallat, 2016). The algorithm processes an image of a retinal fundus, then recognizes the structures of the back layer of the eyeball, allowing to determine whether or not there is diabetic retinopathy. Doctors use a test called "retinal fundus", a technique that allows them to observe the inside of the eyeball through an instrument called an ophthalmoscope, in order to diagnose a disease, or to check the evolution of pathologies.

Diabetic retinopathy (DR), according to the AAO (American Academy of Ophthalmology), is an eye disease that occurs in people with diabetes. For patients with type 1 diabetes, they present or will present a certain degree of DR during their lifetime. For type 2 patients, not all will develop diabetic retinopathy, a high percentage will, but not all. This disease causes damage to the blood vessels of the retina, since the high levels of glucose in the blood cause these molecules to couple to one another, producing an impediment in the flow of blood, which will dry out the vessel and later swell and present fluid leaks, such as plasma with fats (lipids), as blood hemorrhages, affecting the patient's vision.

The algorithm present in this research is loaded with the image of the medical examination to be consulted, this modifies it with the standard image size that is a requirement to the artificial neural network, then the image is processed by this network, delivers a result based on their learning by methods of Deep and Transfer Learning. The result is a prediction of one of the five degrees or states that this disease possesses, that is, a range from a healthy patient to a patient with proliferative grade retinopathy, which is the one with the most progress, probably a patient with blindness.

Finally, the system developed presents an efficacy of 97.78 % for the prediction of diabetic retinopathy present in fundus exams.

Keywords: Diabetes, Diabetic Retinopathy, Retinal Fundus, Convolutional Neural Network.

Índice general

Resumen	I
Abstract	III
Índice de figuras	VII
Índice de tablas	IX
1. Introducción	1
1.1. Definición del Problema	2
1.2. Objetivos del proyecto	3
1.2.1. Objetivo General	3
1.2.2. Objetivos Específicos	3
1.3. Hipótesis	3
1.4. Metodología de Trabajo	4
1.5. Resultados obtenidos	5
2. Marco Teórico y Estado del Arte	7
2.1. Redes Neuronales Convolucionales	7
2.1.1. Convolución	8
2.1.2. SubSampling o SubMuestreo	8
2.1.3. Data Augmentation	9
2.1.4. Deep Learning o Aprendizaje Profundo (DL)	9
2.1.5. Transfer Learning o Transferencia de Aprendizaje(TL)	10
2.2. Retinopatía diabética	11
2.2.1. Clasificación de la enfermedad	12
2.2.2. Detección Automática	13
3. Método Propuesto	15
3.1. Arquitectura del modelo de red neuronal	16

3.2.	Alcances del método	16
3.2.1.	Muestras de fondos de retina	17
3.2.2.	Factibilidad técnica	18
3.3.	Preprocesamiento de datos	18
3.3.1.	Distribución del dataset	18
3.3.2.	Ecualización de imagen CLAHE	19
3.3.3.	Estandarización de las medidas de las imágenes	20
3.3.4.	Normalización del valor de cada pixel	20
3.3.5.	Transformación de variables numéricas a tipo categóricas . .	21
3.3.6.	División de datos para entrenamiento y validación	21
3.3.7.	Validación del modelo	22
4.	Desarrollo Experimental	23
4.1.	Primer experimento: Distribución Original & DL	23
4.1.1.	Conjunto de datos desbalanceado	23
4.1.2.	Parámetros del primer modelo	24
4.1.3.	Resultados del entrenamiento	24
4.2.	Segundo experimento: Augmented Data & TL	25
4.2.1.	Conjunto de datos balanceado	25
4.2.2.	Parámetros de entrenamiento	25
4.2.3.	Resultado del entrenamiento	26
4.3.	Análisis de los resultados obtenidos	26
5.	Discusión y Conclusiones	31
5.1.	Conclusiones de la investigación	31
5.1.1.	Trabajo Futuro	32
A.	Lista de Acrónimos	33
Bibliografía		35

Índice de figuras

1.1.	Ilustración del método científico	5
2.1.	Ilustración de Red Neuronal Convolutional	8
2.2.	Ilustración del método Pooling	9
2.3.	Fondo de retina que presenta retinopatía diabética	11
3.1.	Muestras legibles e ilegibles de fondos de retina	17
3.2.	Distribución de clases de los conjuntos de datos	19
3.3.	Fondo de retina con grado proliferante	20
3.4.	Fondo de retina con grado proliferante filtrado con CLAHE	20
3.5.	Ilustración de la transformación de variables numéricas a tipo categóricas	21
4.1.	Gráfica de pérdida del primer experimento	24
4.2.	Gráfica de precisión del segundo experimento	24
4.3.	Gráfica de pérdida del segundo experimento	26
4.4.	Gráfica de precisión del segundo experimento	26

Índice de tablas

4.1. Métricas de pérdida y presición para el entrenamiento y validación para cada modelo.	27
4.2. Precisión de los modelos para predicción por cada clase.	27

Capítulo 1

Introducción

Las redes neuronales convolucionales, son una rama en el campo de la inteligencia artificial, que han resultado bastante útiles y eficientes en el reconocimiento de patrones en imágenes (Wu, 2017). Debido a la jerarquización presente en las capas de la red, son capaces de ir aprendiendo y reconociendo patrones, que cada vez son más complejos y engloban un concepto.

Si bien en un principio la idea de procesar imágenes con redes neuronales, no estaba desarrollada específicamente con CNN (Convolutional Neural Network), tal como el enfoque para el reconocimiento de caracteres, como por ejemplo números del 0 a 9, presente en el artículo *Handwritten Digit Recognition with a Back Propagation Neural Network* (LeCun et al., 1990). Hoy en día debido a los avances tecnológicos del hardware, así como mejoras en la codificación del software, han permitido que las CNN puedan usarse en detección de enfermedades, tal como la clasificación de enfermedades del tórax desde una imagen de radiología (Guan et al., 2018), por lo que este proyecto busca demostrar la utilidad y valor agregado que posee el uso de estos modelos, como lo es agilizar el proceso médico, tanto para el paciente, como para el doctor. Esto indica que teniendo un modelo funcional, trabajando en una aplicación con interfaz de usuario, un tecnólogo médico podría hacer el trabajo de hacer el exámen a la vista, pasarlo por el algoritmo de detección automática y poder obtener información instantánea de la existencia de retinopatía diabética para el paciente, pero teniendo en cuenta que está sujeta a una revisión del doctor.

1.1. Definición del Problema

La diabetes es una enfermedad crónica que se presenta en una persona cuando su páncreas no produce la insulina suficiente o cuando esta no es utilizada eficientemente, según la Federación Internacional de Diabetes (IDF). Esta enfermedad es una importante causa de la insuficiencia renal, accidentes cerebrovasculares, amputación de los miembros inferiores, infartos al miocardio y ceguera, la cual es el foco del proyecto (Diabetes, Retinopatía Diabética, Organización Mundial de la Salud). El número de personas con diabetes, según la Organización Mundial de la Salud (OMS) ha aumentado de 108 millones desde el año 1980 a 422 millones en 2014, estadística obtenida con el informe anual de NCD-RisC efectuado el año 2016. Esto indica que un gran porcentaje de esas personas puede tener algún síntoma mencionado anteriormente, y para fines de este proyecto se busca determinar si un paciente posee señales de dicha enfermedad. A veces el ser humano es descuidado, por lo que puede surgir un error en el momento de observar y es aquí donde existe una oportunidad con el reconocimiento y/o procesamiento de imágenes con CNN, herramienta que puede brindar apoyo al diagnóstico de un médico sobre un paciente que posea condiciones o señales de RD en la prueba de fondo de ojo, o bien, tener señales y no padecerla. Con el fin de agilizar el proceso médico, y sólo como ejemplo, priorización de listas de espera de manera automática por estado de la enfermedad.

1.2. Objetivos del proyecto

1.2.1. Objetivo General

Clasificar imágenes de fondos de retina a través del procesamiento de redes neuronales convolucionales, con el fin de detectar retinopatía diabética.

1.2.2. Objetivos Específicos

En el presente trabajo, se han definido los siguientes objetivos específicos:

- Recopilar material bibliográfico sobre diabetes, retinopatía diabética y redes neuronales convolucionales.
- Preprocesar dataset para entrenamiento de red neuronal convolucional con imágenes de fondos de ojo de pacientes sanos y pacientes con retinopatía diabética.
- Desarrollar algoritmo usando un modelo de red neuronal convolucional para procesamiento de imágenes, bajo dos métodos de aprendizaje.
- Verificar diagnóstico del algoritmo en base a métricas de calidad, determinadas por la función de pérdida y precisión.

1.3. Hipótesis

La investigación propuesta busca establecer una ayuda al diagnóstico médico de un fondo de ojo en pacientes que presenten características o síntomas de RD. Para ello hace uso del procesamiento de estas imágenes de exámenes oculares para hacer el entrenamiento de redes neuronales convolucionales y así obtener una precisión del 70 % o superior enfocado a detectar si el paciente posee dicha enfermedad.

Se establece un criterio de precisión del 70 % como mínimo, ya que un porcentaje menor podría dar a entender que el algoritmo no tiene una agudeza que permita demostrar confiabilidad en el diagnóstico. Esto significa que si el algoritmo logra una precisión del 50 % sería equivalente a lanzar una moneda al aire para determinar si un paciente posee dicha enfermedad, o sea que el diagnóstico sería completamente estocástico. El artículo Physicians' Diagnostic Accuracy, Confidence, and Resource Requests (Meyer et al., 2013) muestra en sus resultados que en los casos médicos más fáciles, la precisión del diagnóstico es de un 55,3 %, mientras que en los casos

más difíciles sólo llega a un 5,8% por lo que, una precisión del 60% en el algoritmo CNN demuestra que la red empieza a reconocer mejor los patrones en las imágenes, pero aún no es un rango aceptable que pueda ayudar al diagnóstico de un médico, dado que la finalidad de esta memoria es entregar un aporte confiable a un diagnóstico, de ahí nace la idea de fijar la precisión al 70%.

Esto no quiere decir que si el algoritmo posee la precisión mencionada o mayor, será mejor que el entrenamiento de un médico, pero sí será una herramienta útil para complementar el diagnóstico del especialista, de manera que un tecnólogo podrá hacer uso del algoritmo, y agilizar el proceso médico.

1.4. Metodología de Trabajo

El método a usar en esta investigación es el método científico. Método conocido como la aplicación persistente de la lógica como característica común de todo conocimiento razonado. Desde este punto de vista, el método científico es simplemente la forma en que probamos las impresiones, opiniones o suposiciones al examinar la mejor evidencia disponible a favor y en contra de ellas (Cohen, 2011).

- **Realizar Pregunta:** ¿Es posible detectar y clasificar retinopatía diabética por medio del uso de redes neuronales convolucionales?
- **Realizar Investigación:** Se recopila material bibliográfico de CNN y RD con el fin de conocer el marco teórico necesario y el estado del arte presente en este tipo de actividades. Cumpliendo con el primer objetivo de los objetivos específicos.
- **Construcción de Hipótesis:** Se establece un criterio de precisión de un 70% o superior con el fin de establecer una ayuda al diagnóstico médico.
- **Experimentar:** Consiste en la preparación de los datos o imágenes en este caso para la puesta a prueba de los métodos encontrados y desarrollados que se basan en el marco teórico (*Deep y Transfer Learning*), con el fin de resolver la hipótesis planteada y si esta cumple el propósito. Este punto hace la inclusión de los 3 objetivos específicos faltantes por desarrollar, pero no es el término ya que aun no se efectúa el análisis de lo ocurrido.
- **Análisis de Resultados:** Esta fase comprende la observación e indagación del porqué se obtuvo tales resultados. De acuerdo a lo analizado se decide si la solución encontrada satisface la hipótesis total o parcialmente. En caso de ser una solución parcial o falsa, se debe iterar nuevamente para encontrar

una solución o explicación que pueda determinar la razón de los resultados obtenidos.

- **Realizar Informe:** Una vez obtenidos los análisis correspondientes y justificados, independientemente si la hipótesis fue resuelta o no, plasmarlos y explicarlos, para poder concluir cuales fueron los resultados a los que llegó la investigación, y el por qué de estos.

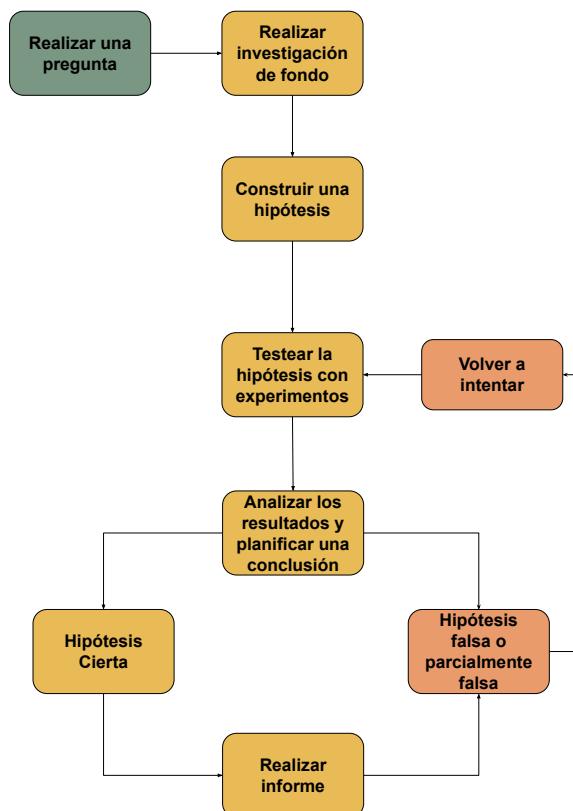


Figura 1.1: Ilustración del método científico.

1.5. Resultados obtenidos

La investigación presente desarrolló 2 experimentos con el fin de testear y comprobar la hipótesis. El primero de ellos consiste en el uso de la técnica de aprendizaje *Deep Learning*, para el entrenamiento en un conjunto de datos desbalanceado por clases, alcanzando una precisión de 79,34 % y una pérdida de 20,04 %.

El segundo experimento evidencia el cambio en los resultados del aprendizaje al someter el conjunto de datos a una técnica de balance llamada *Data Augmentation*,

por medio del aprendizaje por *Transfer Learning*, alcanzando una precisión de 97,78 % y un 6 % de pérdida, demostrando una gran mejora.

Capítulo 2

Marco Teórico y Estado del Arte

2.1. Redes Neuronales Convolucionales

Se sabe que las redes neuronales convolucionales son un tipo de red, que posee enfoque en la detección de patrones en imágenes para así lograr entender un concepto (O'Shea and Nash, 2015). Para lograr esa tarea existen métodos que logran resolver esta detección de manera eficiente, hay que entender que las imágenes poseen millones de píxeles, por lo que cada uno de esos píxeles es un número que representa un color, pero este número es el que la red neuronal entiende, por lo que si se desea trabajar con una imagen de una calidad baja, suponiendo unos 60x60 píxeles, la red neuronal tendrá que trabajar con la multiplicación de éstos, dando lugar a 3.600 píxeles, bajo esa premisa, ¿Qué sucede con una imagen que posee resoluciones mayores?. Supongamos trabajar con una imagen FHD (Full High Definition) de resolución 1920x1080 píxeles, la red neuronal tendrá una entrada a considerar de 2.073.600 píxeles, haciendo que el problema de trabajar con imágenes sea de un orden sin solución aparente, ya que el tiempo que le tomaría en recorrer esa imagen e ir entendiendo patrones sería inmensamente largo, y así sucesivamente con imágenes que poseen una resolución mayor, como es el caso de imágenes en 4K ($4096 \times 2160 = 8.847.360$ píxeles). Para realizar esta tarea, es que existen dos métodos, mencionados en los puntos 2.1.1 y 2.1.2. El funcionamiento de la red, de manera intuitiva se puede apreciar en la Figura 2.1, la cual muestra un fondo de retina como imagen de entrada a la red. Luego se le aplica la primera convolución (CONV1), haciendo la primera transformación de la imagen. Le sigue una capa de Pooling para reducir dimensionalidad, luego se repite el proceso hasta llegar a la capa FC (Fully-Connected), la cual está compuesta de un numero N

de neuronas para procesamiento de las características encontradas en los procesos anteriores, entregando esto al último proceso llamado SOFTMAX, capa que devuelve una distribución de probabilidades, de la cual se elige la alternativa con mayor probabilidad. Este resultado es la clasificación predicha por el modelo.

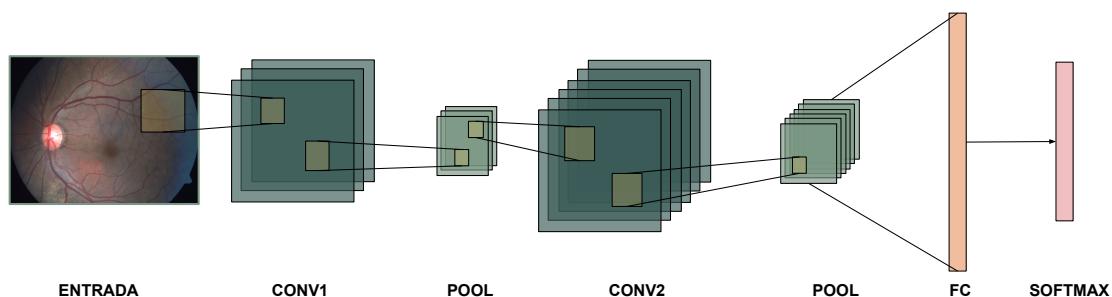


Figura 2.1: Representación de una CNN.

2.1.1. Convolución

La convolución es un método que crea un filtro de una resolución menor que irá dividiendo la imagen en imágenes más pequeñas con resoluciones más bajas, lo que da lugar a que las primeras capas de la red neuronal puedan trabajar entendiendo patrones más simples que luego se transformaran en patrones complejos, y al ser imágenes más pequeñas significa que los píxeles de entrada son menores a trabajar mejorando el rendimiento de análisis (O’Shea and Nash, 2015).

Este proceso se evidencia en la Figura 2.1, concretamente en las capas llamadas “CONV1” y “CONV2”, abreviación para Convolucional 1 y Convolucional 2, donde se aprecia lo mencionado en el primer párrafo, sobre el aumento de imágenes o conocido como profundidad.

2.1.2. SubSampling o SubMuestreo

Subsampling, método normalmente conocido en este campo como pooling el cual complementa a la convolución, haciendo que la imagen “ pierda calidad” sin perder la información importante de la imagen que pueden ser patrones. Esto significa que si la imagen en la primera convolución encontró patrones por las gradientes de colores en la imagen, como puede ser una línea amarilla, el algoritmo ya no tendrá una imagen una línea amarilla con grados de amarillo rey, amarillo pato, sino que sólo se quedará en amarillo. Estos dos métodos se pueden apreciar mejor a continuación con la Figura 2.2, que muestra una aplicación del subsampling

llamada Max Pooling, la cual obtiene el máximo valor de un conjunto de colores en una matriz que representa la imagen.

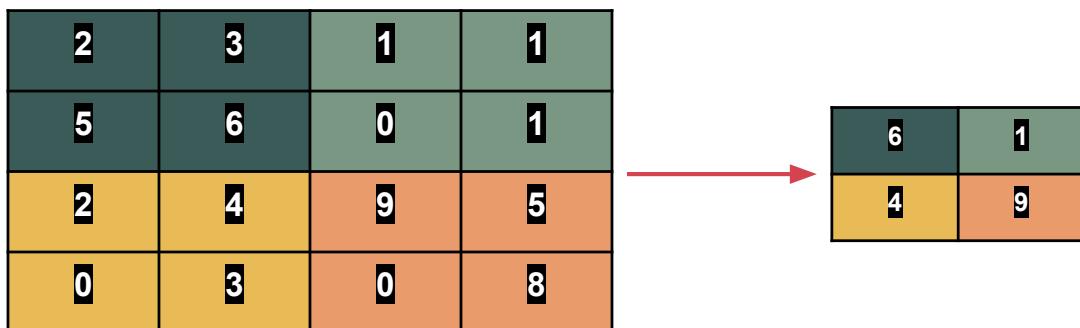


Figura 2.2: Matriz de la izquierda representa los píxeles de una imagen, con su valor asociado antes de aplicar Max Pooling. La matriz en la derecha demuestra el Max Pooling aplicado.

2.1.3. Data Augmentation

Un problema habitual en *Deep Learning* es la gran cantidad de datos necesaria para el entrenamiento de modelos, lo que podemos solucionar con datos aumentados (Van Dyk and Meng, 2001). Es aquí donde entra la técnica *Data Augmentation* que, como indica su nombre, nos permite aumentar nuestro conjunto de datos de dos formas. La primera de ellas consiste en ir introduciendo perturbaciones en los datos originales, por ejemplo elegir una imagen original centrada, y la replicamos descentrada, invirtiendo ejes, etc.

La segunda forma consiste en utilizar distintas distribuciones, por ejemplo si queremos entrenar un modelo para clasificar imágenes de alta resolución, añadimos imágenes de baja resolución, con ruido, o filtros, siempre manteniendo la mayor proporción de alta resolución.

2.1.4. Deep Learning o Aprendizaje Profundo (DL)

El aprendizaje profundo permite que los modelos computacionales que se componen de múltiples capas de procesamiento aprendan representaciones de datos con múltiples niveles de abstracción. Estos métodos han mejorado drásticamente el estado de la técnica en reconocimiento de voz, reconocimiento de objetos visuales, detección de objetos y muchos otros dominios, como el descubrimiento de fármacos y la genómica. El aprendizaje profundo descubre una estructura intrincada en

grandes conjuntos de datos mediante el uso del algoritmo de retropropagación para indicar cómo una máquina debe cambiar sus parámetros internos que se utilizan para calcular la representación en cada capa a partir de la representación en la capa anterior. Las redes convolucionales profundas han producido avances en el procesamiento de imágenes, video, voz y audio, mientras que las redes recurrentes han arrojado luz sobre datos secuenciales como texto y voz. (LeCun et al., 2015)

2.1.5. Transfer Learning o Transferencia de Aprendizaje(TL)

La transferencia de aprendizaje (TL), es la mejora del aprendizaje en una nueva tarea a través de la transferencia de conocimientos de una tarea relacionada que ya se ha aprendido. Si bien la mayoría de los algoritmos de aprendizaje automático están diseñados para abordar tareas individuales, el desarrollo de algoritmos que facilitan el aprendizaje por transferencia es un tema de interés continuo en la comunidad de aprendizaje automático (Torrey and Shavlik, 2010).

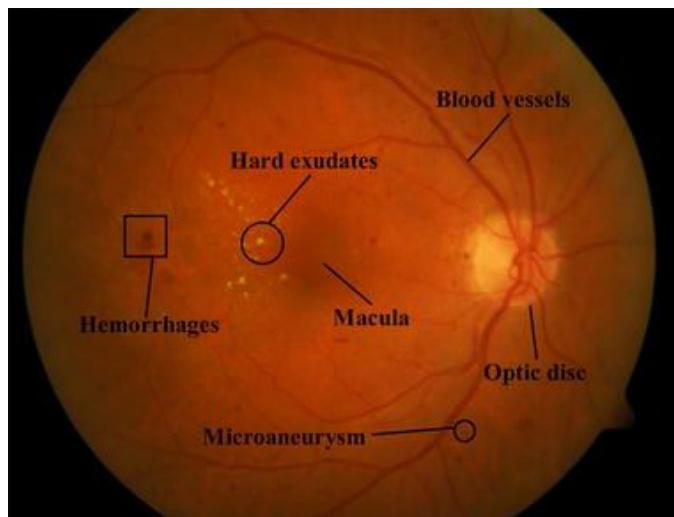


Figura 2.3: Consecuencias de la retinopatía diabética en la anatomía del ojo humano. Se observa hemorragias, exudados duros y microaneurismas. (Xiao et al., 2017)⁵

2.2. Retinopatía diabética

La retinopatía diabética es una enfermedad que afecta los vasos sanguíneos presentes en la retina. Este tejido es muy vascularizado (muchos vasos sanguíneos), el cual se daña debido a las múltiples alteraciones generadas por un conjunto de trastornos metabólicos (Mellitus, 2005).

Los vasos sanguíneos presentes en la retina comienzan a presentar daño en sus capilares debido a la pérdida de pericitos, células contráctiles que se envuelven alrededor de las células endoteliales de los capilares y vénulas en todo el cuerpo. Este daño es causado por el exceso de moléculas de glucosa en la sangre, que se van aglutinando en los vasos produciendo un corte en la circulación, proceso conocido como isquemia. Al dañarse las paredes de los vasos sanguíneos estos comienzan a desgastarse produciendo microaneurismas, que es una hinchazón en forma de “bolsa” debido a la falta de circulación de sangre. Este proceso conlleva a que los vasos pierdan su propiedad de impermeabilidad terminando en filtraciones, ya sea hemorragias o sudoración lipídica (plasma con grasa) (Fong et al., 2004).

Se producen 2 grandes problemas debido a la isquemia en la retina (Klein et al., 1994). Se produce una citoquina (proteína) llamada VEGF (*Vascular Endothelial*

⁵Fuente: *Automatic non-proliferative diabetic retinopathy screening system based on color fundus image.*

Growth Factor), que es un mecanismo de compensación para generar vasos sanguíneos nuevos, provenientes de vasos existentes, conocidos como neovasos o vasos en neoformación. El problema de este mecanismo radica de su crecimiento en la superficie de la retina y en la superficie del humor vítreo, ya que no hacen circular sangre, sólo crecen, por lo que se hinchan y revientan, produciendo sangramiento en la cavidad vítreo, o jalan la retina y la despegan, terminando en ceguera para el paciente. El segundo problema se debe a la fuga de plasma, por la sudoración lipídica, se empieza a producir un cúmulo de grasa alterando la mácula que conlleva a pérdida en la visión.

2.2.1. Clasificación de la enfermedad

La retinopatía diabética se puede clasificar desde las etapas más iniciales o leves, hasta las más avanzadas o graves, de acuerdo a la condición de la retina en el examen de fondo de ojo. La enfermedad se puede dividir en dos categorías, Retinopatía Diabética No Proliferante (RDNP) y Retinopatía Diabética Proliferante (RDP) (MINSAL, 2010).

La RDNP se subdivide a su vez en leve, moderada y severa. Los cambios que produce esta primera condición están limitados a la retina y no pasan más allá de la membrana limitante interna de esta. La RDP se subdivide en temprana, de alto riesgo y avanzada, pero de acuerdo al formato del conjunto de imágenes se hará uso de RPD como sólo una clase y no las 3 divisiones existentes. Posee esta denominación de proliferante o proliferativa por el hecho de que las alteraciones oftalmoscópicas producidas por la isquemia tienen por consecuencia la formación de vasos sanguíneos de neoformación, que atraviesan o proliferan más allá de la retina.

- **Sin RDNP:** Paciente sin alteraciones retinales debido a la diabetes.
- **RDNP Leve:** Microaneurismas, exudados, manchas algodonosas, hemorragias retinianas.
- **RDNP Media:** Hemorragias y/o microaneurismas severos en los 4 cuadrantes presentes de la retina. Rosarios venosos presentes en 2 o más cuadrantes.
- **RDNP Severa:** Coexisten 2 de 3 criterios presentes en la RDNP media.
- **RD Proliferante:** Aparición de neovasos proliferantes de la retina.

2.2.2. Detección Automática

La detección automática de retinopatía diabética no es algo nuevo, ni tampoco algo que se pretenda descubrir en esta memoria, el foco es resolver esta problemática a partir de otros métodos que integran preprocesamiento de la distribución de cantidad de imágenes presente, antes de ser llevado a la red neuronal convolucional. La automatización en la detección de esta enfermedad no sólo se llevó a cabo con redes neuronales convolucionales, sino con otra serie de métodos como lo son las máquinas de soporte vectorial o SVM por sus siglas en inglés, el cual alcanzó una sensibilidad del 82 %, estudio llamado *A fully automated comparative microaneurysm digital detection system* (Cree et al., 1997). En el caso de redes neuronales convolucionales, el artículo *Image processing applied to detection of microaneurysms in fundus images* (Rosas-Romero et al., 2015), presenta un enfoque al preprocesamiento con la normalización del fondo de retina en escala de grises, obteniendo resultados de una sensibilidad de 0,93. Aunque posee diferencias con los alcances de esta memoria, debido a que no se busca probar la efectividad de distintos filtrados de imagen para una búsqueda en la mejora del rendimiento.

No sólo existen enfoques hacia el filtrado de imagen con el fin de obtener mejores resultados para las técnicas de *Deep Learning* para clasificación de retinopatía diabética, sino que existen investigaciones que presentan un enfoque como *Deep neural networks to predict diabetic retinopathy* (Gadekallu et al., 2020), que hace uso de GWO (*Grey Wolf Optimization*), algoritmo que imita la lógica y estructura social de caza de los lobos grises, como analogía de resolución de problemas, en conjunto a un análisis de componentes principales procesada por una CNN, alcanzando una precisión de 96 %.

Capítulo 3

Método Propuesto

Se propone el desarrollo de un algoritmo capaz de procesar imágenes de fondos de retina, con el fin de determinar la existencia de retinopatía diabética, y de ser así, el estado o grado de avance. El algoritmo recibe una imagen de entrada de cualquier tamaño, para luego ser redimensionada a un estándar de 224x224 píxeles. De esta forma la red neuronal recibe esta imagen estandarizada y es procesada para obtener una salida distribución de probabilidades, eligiendo la probabilidad que posea el mayor valor, entendiendo que esa es la clase predicha, dentro de las 5 existentes.

El algoritmo de red neuronal convolucional está entrenado con un conjunto de datos de libre acceso para investigación.

Algorithm 3.1. Algoritmo ya entrenado capaz de predecir la muestra entregada.

- 1: Cargar imagen I
 - 2: Redimensionar la imagen I
 - 3: Convertir imagen I a un arreglo Numpy
 - 4: Estandarizar los valores del arreglo
 - 5: Cargar el arreglo a CNN
 - 6: Ejecutar el modelo CNN
 - 7: **if** predicción(I) == tipo_grado **then**
 - 8: Imprimir nivel de la enfermedad obtenido
 - 9: **end if**
 - 10: Imprimir métricas de la predicción
-

3.1. Arquitectura del modelo de red neuronal

El algoritmo propuesto, consta de un modelo de red neuronal base, sumado a una capa de neuronas profundas, que le sigue una capa de salida de activación Softmax. El modelo de red neuronal base es DenseNet121 o Redes Convolucionales Densamente Conectadas, el cual, para cada capa toma los mapas de características de todas las capas anteriores y se utilizan como entradas, y sus propios mapas de características se utilizan como entradas en todas las capas posteriores. (Huang et al., 2017).

Cuando la imagen ya fue procesada por este modelo base, los parámetros obtenidos son captados y procesados por una capa densa de 256 neuronas, las cuales entregan información a la última capa de 5 neuronas, que es la de salida, con función de activación Softmax, que es la encargada de entregar una distribución de probabilidades para las 5 clases. Por último la función *ARGMAX()* devuelve el mayor porcentaje obtenido con la capa Softmax, entregando una salida de un sólo valor, el cual es la predicción del grado de la enfermedad de la imagen evaluada.

3.2. Alcances del método

El método propuesto se enfoca únicamente en la detección automática de retinopatía diabética con el uso de un previo procesamiento de imágenes de fondos de retina para ser entregadas a una red neuronal convolucional, determinando si posee la enfermedad o no. La clasificación del grado de avance de la enfermedad no es el foco de los alcances del algoritmo en investigación, pero sí se hacen técnicas para trabajar con este problema, debido a que puede afectar la precisión.

La precisión del algoritmo será exclusivamente para el dataset que figura en la investigación. Sin cerrar posibilidad de hacer pruebas de concepto con imágenes pertenecientes a otro dataset, haciendo hincapié en que esas imágenes no son del propósito de estudio, ni figuran en los resultados finales. La precisión del algoritmo se encuentra asegurada para el tipo de muestras utilizadas en la investigación, por lo que muestras mal tomadas, no aseguran un buen rendimiento, esto se explica a mayor detalle en la sección 3.2.1. El hecho que el algoritmo pueda identificar la enfermedad, no significa que pueda reemplazar el trabajo de un médico, por lo que la predicción siempre estará sujeta a una confirmación de un experto.



Figura 3.1: Muestras legibles e ilegibles de fondos de retina. Las muestras legibles están categorizadas por grado de la enfermedad. Las muestras ilegibles no poseen categoría debido a que una muestra así no es considerada, por lo que el paciente debe repetir el exámen. Las muestras legibles fueron preprocesadas con histograma CLAHE con el fin de evidenciar las diferencias entre cada clase.

3.2.1. Muestras de fondos de retina

El conjunto de datos a utilizar posee muestras de buena calidad, de hecho son muy pocas las imágenes que tienen calidad baja o que podrían llegar a considerarse ilegibles. La Figura 3.1 posee una extracción de muestras que son parte del conjunto de datos a utilizar para la investigación, pero también se adjuntan muestras ilegibles, aunque no son parte del conjunto, sino que extraídas de otra fuente. Este tipo de muestras de carácter ilegible no asegura el correcto funcionamiento del algoritmo, debido a que es una falla de una etapa previa al uso del algoritmo.

La efectividad del algoritmo no se asegura para una muestra de mala calidad, ya que el algoritmo no podría diferenciar detalles haciendo omisión de ellos, o estrictamente la imagen es ilegible y dar un resultado aleatorio.

Con respecto a la mala calidad, no se refiere a que el instrumento utilizado para sacar imágenes sea de mala calidad, sino que la manipulación de este instrumento, o alguna etapa posterior al guardado del examen sea erróneo y que por consiguiente, la imagen sea ilegible. Por ejemplo, que la imagen tenga luces tipo flash, o que el

lente no esté calibrado y termine sacando una foto demasiado oscura, que nuble los componentes de la retina. Tampoco hay que confundir que la imagen a procesar debe tener perfecta calidad, pero sí debe ser legible.

3.2.2. Factibilidad técnica

Para el desarrollo del proyecto se debe contar con imágenes de fondos de retina, que estén sanos, como también fondos de retina con distintos grados de la enfermedad objetivo. Un aspecto importante a considerar, es la cantidad de imágenes a utilizar, debido a que las herramientas de inteligencia artificial necesitan una gran cantidad de datos para converger a una solución, es por esta razón que las redes neuronales artificiales dotan de la capacidad de aprendizaje, ya que es el entrenamiento el proceso que da lugar a la utilidad del algoritmo.

Es por ello que se cuenta con un dataset de libre acceso y con fines investigativos que provee la comunidad de Kaggle¹. Este dataset provee la cantidad de 3.662 imágenes. Cada una posee identificación, luego si es el ojo izquierdo o derecho y por último el grado de la enfermedad con escala de 0 a 4, siendo 0 un ojo sano y 4 siendo un ojo con RD proliferante, o sea el grado de avance más severo de la enfermedad.

3.3. Preprocesamiento de datos

Esta sección es una fase demasiado importante para el aprendizaje de una red neuronal, debido a que es la manera en cómo se le entrega la información y con qué calidad la entregamos. Aplicado a las CNN es una etapa que comprende transformaciones a las imágenes de entrada, con finalidad de evitar datos innecesarios que perjudican el rendimiento del algoritmo y de la capacidad de procesamiento del hardware, explicado en la sección 2.1. Es por ello que a continuación se explican las fases por la cual, una imagen se convierte de su estructura original a datos de entrada para una red neuronal.

3.3.1. Distribución del dataset

El conjunto de datos a utilizar posee una distribución original observada en la Figura 3.2, la cual posee un desbalance entre clases, esto significa que posee más

¹Página web de la comunidad: <https://www.kaggle.com>

Distribución Original v/s Distribución Aumentada

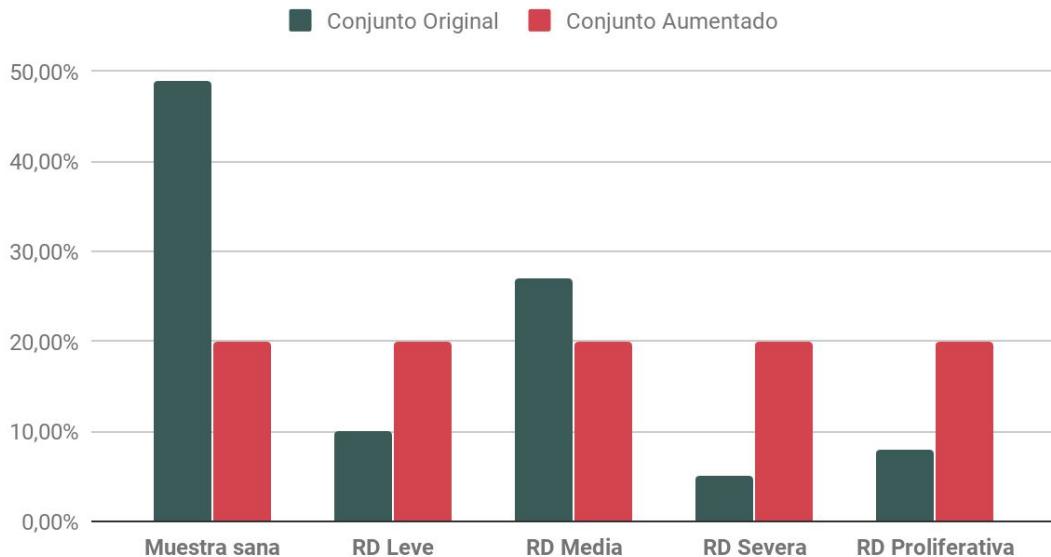


Figura 3.2: Distribución del conjunto de imágenes antes y después de aplicar Data Augmentation.

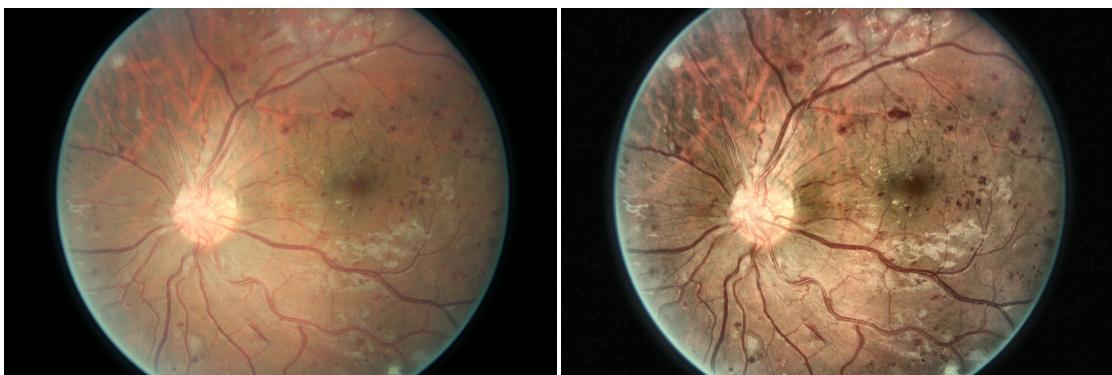
muestras de un tipo de clase, que de las demás. Por lo que la clase predominante en el conjunto de datos es de pacientes con ojos sanos (clase 0). Esto genera inconsistencia en los datos a entrenar, afectando el rendimiento del algoritmo, evidenciado en el capítulo del desarrollo experimental. Para ello se hace uso de Data Augmentation, técnica usada para el tratamiento de conjuntos de datos balanceados, explicado en la sección 2.1.3. Si bien la hipótesis radica en la clasificación de si un fondo de retina se encuentra sano, y no en la clasificación de qué grado se encuentra el paciente, es una característica importante a considerar durante el desarrollo y medición de este algoritmo, pues se ve afectado su rendimiento.

3.3.2. Ecualización de imagen CLAHE

El histograma adaptativo con contraste limitado o Contrast-Limited Adaptive Histogram Equalization por sus siglas en inglés, es un método que ha demostrado ser útil para asignar niveles de intensidad mostrados en imágenes médicas. El método está diseñado para permitir al observador ver fácilmente, en una sola imagen, todo contraste de interés en la investigación clínica (Pizer, 1990). Calcula varios histogramas, cada uno correspondiente a una sección distinta de la imagen, y las utiliza

⁷Fondo de retina con retinopatía diabética grado proliferante.

⁸Fondo de retina con retinopatía diabética grado proliferante con ecualización CLAHE.

Figura 3.3: Imagen original.⁷Figura 3.4: Imagen procesada.⁸

para redistribuir los valores de luminosidad de la imagen. Por tanto, es adecuado para mejorar el contraste local y la mejora de las definiciones de bordes en cada región de una imagen. Aplicado a un fondo de ojo, se obtiene el siguiente resultado visualizado en la Figura 3.3 y 3.4.

Se puede observar que la imagen original tiene apreciación de detalles pero de manera tenue, más aún si está vista bajo un ojo no calificado, como cualquier persona ajena a la medicina o al campo de la oftalmología.

Al pasar la imagen por el ecualizador CLAHE, da cuenta del cambio en el contraste y cómo los detalles sobresaltan, incluso para un ojo no calificado. Por ejemplo, los detalles que poseen mayor cambio a la vista son las hemorragias, pequeñas manchas rojas en el lado derecho del fondo de retina y el nervio óptico.

3.3.3. Estandarización de las medidas de las imágenes

Las imágenes del dataset vienen en calidad 4K, por lo que son de gran calidad y en términos computacionales, son bastante costosas de procesar. Por otro lado, la definición del tamaño de entrada en la red debe ser estático, por lo que no se puede trabajar con distintas medidas. Es por ello que se establece un criterio de estandarización en las medidas, que en este caso es de 224 x 224 pixeles. Aunque la definición de este parámetro no es algo aleatorio, ya que se encuentra presente en los requisitos de entrada de la red neuronal base utilizada en este algoritmo, la cual es DenseNet121.

3.3.4. Normalización del valor de cada pixel

Un pixel ante el ojo humano es un color, pero para el computador es un número que representa un color y para la mayoría de los datos de imagen los valores de los

píxeles son números enteros que rondan entre 0 y 255.

Las redes neuronales procesan entradas usando pesos pequeños, y las entradas con valores enteros grandes pueden interrumpir o ralentizar el proceso de aprendizaje. Como tal, es una buena práctica normalizar los valores de píxel para que cada valor de píxel ronde entre 0 y 1. Es válido que las imágenes tengan valores de píxeles en el rango de 0-1 y las imágenes se pueden ver normalmente.

Esto se puede lograr dividiendo todos los valores de píxeles por el valor de píxeles más grande, lo cual es 255. Esto se realiza en todos los canales, independientemente del rango real de valores de píxeles que están presentes en la imagen.

3.3.5. Transformación de variables numéricas a tipo categóricas

Para mantener todos los números en orden y trabajar bajo una misma escala, los grados de la enfermedad (0-4) también deben trabajarse en ese estilo, con esta transformación evitamos números mayores a 1. Para lograr esto, las variables numéricas se convierten a variables categoricas, o sea que su valor puede ser 0 o bien un 1. La Figura 3.5 muestra el cambio de formato.

Nombre	Grado	0	1	2	3	4
fondo_1	0	1	0	0	0	0
fondo_2	1	0	1	0	0	0
fondo_3	2	0	0	1	0	0
fondo_4	3	0	0	0	1	0
fondo_5	4	0	0	0	0	1

Figura 3.5: La imagen izquierda muestra el nombre de la imagen junto a el grado de la enfermedad. La imagen derecha muestra el proceso de transformación de variable numérica a categórica.

3.3.6. División de datos para entrenamiento y validación

De acuerdo a la poca cantidad de imágenes presentes en la distribución original del conjunto de datos, se busca priorizar la mayor cantidad de imágenes para el entrenamiento del modelo. Es por ello que se fijará una división del conjunto en

95 % de datos para entrenamiento (3.479 muestras) y 5 % de datos para validación (183 muestras).

Para el segundo experimento también se fijará esta distribución con el fin de comparar los resultados de manera más equilibrada o con condiciones similares, con 8.550 imágenes de entrenamiento y 450 imágenes de validación.

Para esta división se hará uso de la función *Train_Test_Split()* que provee la librería de herramientas *Scikit Learn*, en conjunto a su parámetro *Stratify*, el cual permite conservar la misma cantidad de imágenes por clase, tanto para el conjunto de entrenamiento, como para el de validación. Esta función crea dos arreglos de manera aleatoria, pero que debido a un parámetro llamado *Random State*, permite reproducibilidad, o sea, fijar las condiciones iniciales para que las imágenes aleatorias sean las mismas siempre, al momento de dividirse.

3.3.7. Validación del modelo

Para el estudio y validación de los valores obtenidos por el entrenamiento de estos modelos, se utilizarán las métricas de pérdida y precisión que provee la librería de *Keras*. Esta librería en su glosario explica que la función de pérdida calcula el error de la ecualización de los pesos de la red, con respecto a la curva y división original de los datos. En cuanto a la variable de precisión, *Keras* muestra que esta métrica crea dos variables locales, Verdaderos Positivos y Falsos Positivos. Esta métrica es una simple operación que divide los Verdaderos Positivos sobre la suma de Verdaderos Positivos y Falsos Positivos. Por lo que la investigación debe alcanzar sobre el 70 % de precisión para satisfacer la hipótesis planteada.

Capítulo 4

Desarrollo Experimental

El desarrollo experimental de esta memoria consta de 3 etapas, 2 de ellas son experimentos y la última consiste en el análisis de las etapas anteriores. Los experimentos tienen como fin corroborar la hipótesis a base de distintas configuraciones, eligiendo la que cumpla el propósito con mejores resultados. La importancia de este proceso es la capacidad de observar su comportamiento a base de medir la solución encontrada, y si esta necesita mejoras, trabajar en ello para desarrollar un modelo más pulcro, en el sentido de minimizar errores.

El experimento 1 consiste en entrenar la red neuronal por medio del método de *Deep Learning*, con el conjunto de datos de forma original como lo provee la comunidad de Kaggle, por lo que presenta inconsistencia entre la cantidad de imágenes por clase, o sea, presenta desbalance. El experimento 2 consiste en el entrenamiento de la red neuronal bajo el método de *Transfer Learning* y el conjunto de datos aumentado, o sea balanceado para la cantidad de imágenes por clase, por el uso de la técnica *Data Augmentation*, con el fin de disminuir los posibles errores y sesgos debido a la inconsistencia de la distribución original.

4.1. Primer experimento: Distribución Original & DL

4.1.1. Conjunto de datos desbalanceado

Los datos a usar en el primer experimento es el conjunto original que provee la comunidad de Kaggle con fines educativos. Este conjunto posee un desbalanceo entre las clases mencionado en el punto 3.3.1 y su distribución puede ser visualizada

en la Figura 3.3. Por lo que los resultados obtenidos estarán condicionados a partir de ese aspecto.

El conjunto de datos a utilizar viene tal y como un médico observaría un fondo de retina a color, por lo que no ha sido preprocesado con filtros de imagen, como se evidencia en la Figura 3.3. El único preprocesamiento que ha tenido el conjunto, ha sido la reducción del tamaño de las imágenes a un estándar de 224 píxeles de alto por 224 píxeles de ancho, debido a que la red neuronal posee esos requisitos de entrada, mencionados en el punto 3.3.3.

4.1.2. Parámetros del primer modelo

Para el desarrollo de esta primera fase experimental es que el entrenamiento será con el modelo base de redes neuronales convolucionales DenseNet121 agregado a una capa profunda de 256 neuronas seguido de una capa de distribución de probabilidades llamada SoftMax. La capa base DenseNet121 tiene el uso de la técnica de aprendizaje Deep Learning.

La configuración de la tasa de aprendizaje será de $lr = 0,00001$, la cual es baja con el fin de evitar que el aprendizaje del modelo se estanque en un mínimo local y no al mínimo total, alcanzando, resultados más precisos.

4.1.3. Resultados del entrenamiento

Esta fase comprende el algoritmo siendo puesto a prueba bajo las configuraciones mencionadas en los dos puntos anteriores.

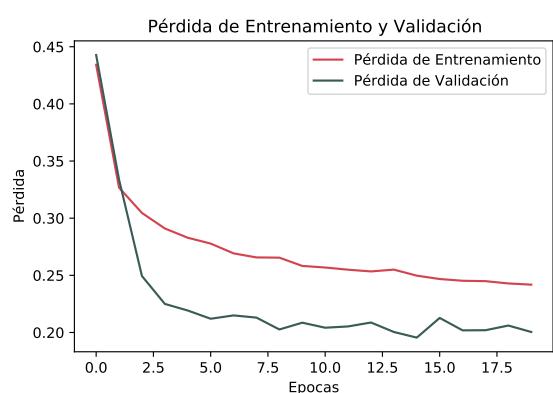


Figura 4.1: Función de pérdida con Deep Learning.

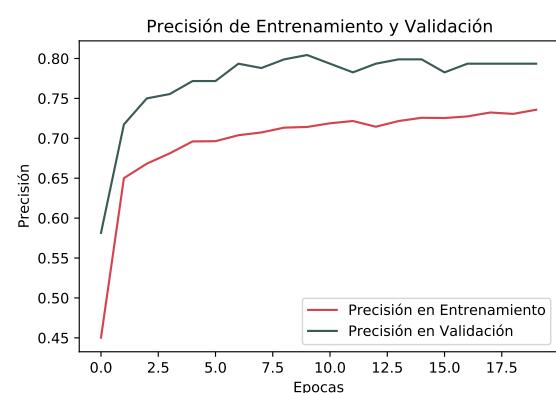


Figura 4.2: Precisión obtenida con Deep Learning.

Las Figuras 4.1 y 4.2 muestran el comportamiento que tuvo Deep Learning con 20

épocas de entrenamiento. El gráfico de pérdida muestra el recorrido del aprendizaje y validación de estas configuraciones. Se aprecia que la curva de entrenamiento alcanza una pérdida de 25 %, siendo mayor a la pérdida observada en la curva de validación, la cual posee una diferencia de 5 %, alcanzando un nivel más bajo en el error de las predicciones, con un 20 %.

La Figura 4.2 evidencia la precisión obtenida del aprendizaje de este modelo, como también la validación de ese aprendizaje. Se observa que la curva de precisión durante el entrenamiento alcanza un nivel menor a la curva de validación. La curva de entrenamiento alcanza un valor ligeramente superior al 70 %, mientras que la curva de validación supera ligeramente el 75 %.

4.2. Segundo experimento: Augmented Data & TL

4.2.1. Conjunto de datos balanceado

Para esta segunda fase del desarrollo experimental se hace uso de la técnica *Data Augmentation*, explicada en el punto 2.1.3. La idea de su uso radica en balancear esa diferencia existente por clases, por lo que el valor de muestras por clase es de 1.789 aproximadamente, haciendo un conjunto de 9000 muestras en total. En la distribución original, la única clase que alcanza ese número de muestras es la de pacientes sanos, es por ello que se hizo este aumento de muestras en las siguientes 4 clases, alcanzando la misma cantidad que las muestras de pacientes sanos, generando un balance en la distribución con un 20 % por clase, como se observa en la Figura 3.3.1. El aporte a la investigación que posee este punto, es verificar si se obtiene una mejora en la predicción y precisión del modelo.

4.2.2. Parámetros de entrenamiento

La segunda fase del desarrollo experimental a diferencia de la primera, hace uso del método *Transfer Learning*, el cual debería mostrar mejores resultados que el primer experimento y corroborar lo mencionado en el punto 2.1.5. La tasa de aprendizaje a utilizar será la misma anterior $lr = 0,00001$, con el mismo fin de no estancar el aprendizaje en un mínimo local.

4.2.3. Resultado del entrenamiento

Las Figuras 4.3 y 4.4 muestran las curvas obtenidas durante el entrenamiento con técnica de Transfer Learning.

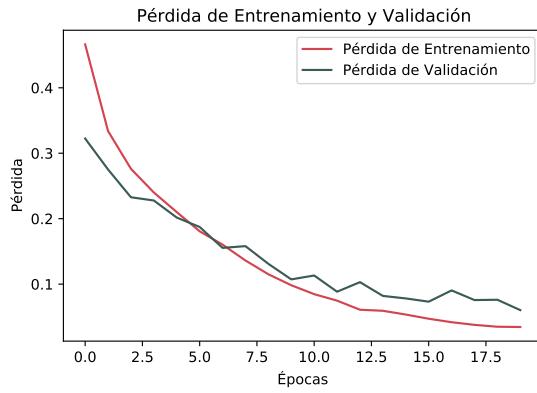


Figura 4.3: Pérdida bajo Transfer Learning.

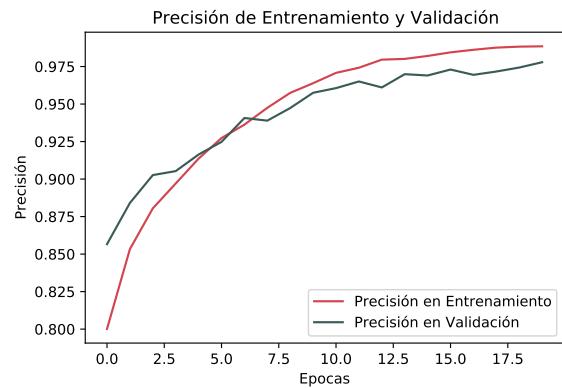


Figura 4.4: Presición bajo Transfer Learning.

Las curvas presentes en la Figura 4.3 muestra que la pérdida del aprendizaje sigue una trayectoria bastante similar con la curva de validación. La curva de entrenamiento posee un inicio superior al 40 % de error y converge en un valor menor al 10 % mientras que la curva de validación inicia ligeramente superior al 30 % de error y converge en un valor también menor al 10 % pero siendo levemente superior que el de entrenamiento. La Figura 4.4 muestra un comportamiento similar de los aciertos del entrenamiento, como los de validación. La curva de precisión del entrenamiento empieza en 80 % mientras que la de validación en un 85 %, llegando a converger las dos en un valor cercano al 98 %.

Se observa en la Tabla 4.1 las diferencias en los valores, tanto de pérdida y precisión durante el entrenamiento, como en validación, que cada modelo alcanzó. La Tabla 4.2 muestra la cantidad de aciertos que cada modelo obtuvo con distintos métodos de entrenamiento aplicado al conjunto de validación, por cada clase del conjunto de datos.

4.3. Análisis de los resultados obtenidos

El primer experimento muestra que el entrenamiento con un conjunto de datos desbalanceado con la técnica de Deep Learning sí resuelve el propósito de la hipótesis propuesta, es más supera por un 9 % la precisión esperada, por lo que es un método que funciona o cumple primeramente la tarea. Se comprueba que Deep Learning

Modelo	Pérdida Entrenamiento	Precisión Entrenamiento	Pérdida Validación	Precisión Validación
Deep L	24,18 %	73,57 %	20,04 %	79,34 %
Transfer L	3,44 %	98,84 %	6,02 %	97,78 %

Tabla 4.1: Métricas de pérdida y presición para el entrenamiento y validación para cada modelo.

Modelo	Clase 0	Clase 1	Clase 2	Clase 3	Clase 4
Deep L	93,33 %	50,00 %	86,00 %	0 %	0 %
Transfer L	100 %	84,44 %	86,67 %	96,67 %	94,50 %

Tabla 4.2: Precisión de los modelos para predicción por cada clase.

sí es una herramienta útil en la identificación y clasificación de enfermedades, sin dejar de lado que siempre estará bajo la supervisión de un profesional, aunque existe un detalle bastante importante el cual es el desbalance de clases durante el entrenamiento del algoritmo. Como se observa en la Tabla 4.2 el algoritmo entrenado con Deep Learning es capaz de predecir correctamente la clase de pacientes sanos (Clase 0) con un 93,33 % de aciertos, esto se debe a que esta clase posee un mayor número de muestras que las otras, por lo que el conjunto de imágenes de validación también presenta este desbalance entre muestras. La cantidad de aciertos por clase se ve afectada en base a su distribución, y tal como se observa en la Figura 3.2, a menor cantidad de muestras por clase, peor es el rendimiento, demostrado en la cantidad de aciertos de las muestras de retinopatía diabética severa y proliferante (Clase 3 y 4), las cuales son las clases con menor cantidad de muestras. Independientemente de que las Figuras 4.1 y 4.2, muestran que la curvas tienen tendencia a seguir disminuyendo, no significa que a mayor cantidad de épocas mayor precisión se obtendrá, aunque así se observe en las curvas obtenidas, debido a que existe un problema conocido como “Sobreaprendizaje o Sobreajuste”, que perjudica la precisión del modelo, ya que la red se estaría aprendiendo las respuestas de “memoria” y no estaría generalizando, que es el propósito de una red neuronal artificial. Otro argumento a favor de que a mayor cantidad de épocas no se garantiza un mejor resultado, es el hecho que si se observa la Figura 4.2, desde antes de la tercera iteración, el algoritmo ya empieza a clasificar de una manera más correcta, el conjunto de datos de distribución original, por lo que el aumento en la precisión cambia de valor de manera más leve. Esto también se observa en la Figura 4.1, donde la pérdida empieza a disminuir de manera leve, desde la segunda

iteración.

Por otra parte se observa que en las Figuras 4.1 y 4.2, que la curva de validación, tanto para la gráfica de pérdida y precisión, posee mejores resultados que la curva de entrenamiento, siendo que el común debería ser al revés. Esto se explica de igual forma con el desbalance entre las clases, ya que se puede abordar desde las siguientes dos ideas. La primera es que las imágenes presentes en las clases 3 y 4 del conjunto de datos para entrenamiento posean muestras más difíciles de interpretar, por lo que la red neuronal no puede establecer las diferencias que existen por grado de la enfermedad. La segunda idea es que el conjunto de validación posee mayor número de muestras fáciles a predecir, que serían de las clases donde existe un mayor número de muestras en el entrenamiento, en concreto la clase 0 y 2, dada la distribución presente en la Figura 3.3.1.

La única solución aparente a este problema y demostrada en esta memoria es el balance del conjunto de datos, haciendo que las clases que tenían menor cantidad de aciertos, de un 0 % de aciertos para las clases con menor cantidad de muestras, ahora superen el 94 % de precisión, por lo que el segundo modelo posee un desempeño muy superior que el primero y para todas las clases.

Existe un elemento más en el desarrollo experimental a explicar, el cual es el aporte de la técnica Transfer Learning. Si bien los resultados obtenidos con Deep Learning no eran malos, aún debían perfeccionarse, y se demuestran en las curvas de pérdida y precisión obtenidas en el segundo experimento, concretamente las Figuras 4.3 y 4.4, donde el error o pérdida del modelo es de un 6 % y la precisión es de un 97,78 %. Se puede comprobar al observando los valores de inicio de estas curvas, concretamente en la Figura 4.4, donde la precisión parte desde un 80 % para el aprendizaje y desde un 85 % en la validación, que finalmente convergen en valores muy cercanos que rodean al 97,5 %. Esto también se corrobora en las similitudes de la Figura 4.1 y 4.3, ya que la pérdida en ambos métodos, o sea, Deep Learning y Transfer Learning, comienza desde un 40 %. La diferencia de estas dos figuras radica en que el entrenamiento bajo Transfer Learning, posee una pérdida menor desde un inicio para la curva de validación, y para la de entrenamiento en vez de estancarse en un número cercano al 25 %, sigue disminuyendo hasta alcanzar un 6 %. Una diferencia de un 19 %, que es bastante significativa. Por lo que aporta un plus al objetivo principal de la memoria, obteniendo un modelo mucho más ajustado y con mucha menor diferencia entre predicción por clases durante el entrenamiento.

Si bien el foco de esta memoria es la identificación si un paciente posee o no

señales de retinopatía diabética y no la clasificación por grado de la enfermedad que tampoco pertenece a los alcances del algoritmo, es un tópico que afecta de manera directa al enfoque y propósito del proyecto, es por ello que se hizo uso de la técnica *Data Augmentation*. No obstante, aunque la hipótesis de la investigación se cumple usando el conjunto desbalanceado con los resultados obtenidos, se demuestra que para la realización de un buen modelo, este tiene que ser trabajado con búsqueda de la menor cantidad de sesgos posibles.

Capítulo 5

Discusión y Conclusiones

5.1. Conclusiones de la investigación

Esta investigación comprende de un proceso de decisión en base a valores obtenidos para determinar qué método resuelve de mejor forma la hipótesis propuesta. Se propuso el desarrollo de un algoritmo que procesa exámenes oculares en formato de imagen para ser evaluados por medio de una CNN, la cual a partir de la información obtenida que posee la imagen, entrega un resultado si esa muestra posee o no señales de la enfermedad objetivo. Esta red neuronal artificial, está diseñada con una arquitectura base DenseNet121, junto a una capa profunda de 256 neuronas, seguida de una capa de 5 neuronas de salida con función de activación Softmax, la cual es una distribución de probabilidades. La diferencia se encuentra en el método implementado para el proceso de aprendizaje, los cuales son Deep y Transfer Learning y en el conjunto de datos a usar por experimento.

Inicialmente se experimenta con el método de aprendizaje Deep Learning junto a el conjunto de datos con su distribución original, en el cual se observa la diferencia de muestras por clase. De aquí se obtienen resultados que cumplen el resultado esperado del proyecto, alcanzando una precisión de 79,34 % y una error de 20,04 %, pero que demuestran un modelo con imperfecciones en sus predicciones debido a este desbalance. Es por ello que se implementa el segundo método que posee dos diferencias, respecto al anterior, las cuales son el uso del método de aprendizaje Transfer Learning, sujeto a un conjunto de datos con distribución balanceada, como resultado de la aplicación de la técnica *Data Augmentation*. Los resultados obtenidos con este cambio son significativos en comparación al primer experimento, es más, corrige un gran problema implícito, que es la mejora en las predicciones

debido a que puede reconocer las diferencias existentes por clase, problemática que el algoritmo entrenado con DL no pudo resolver correctamente. Por lo que se comprueba que TL es capaz de obtener un resultado más preciso que el obtenido por DL y en menor tiempo, alcanzando una precisión de un 97,78 % y una pérdida de un 6 %.

El aporte de esta investigación al enfoque médico, es la agilización de los procesos de toma de exámenes y organización de los datos en una empresa. Tal como se recalca en varios puntos de esta memoria, la solución propuesta no reemplaza y no reemplazará la capacidad del personal médico para determinar y tomar una acción, sino que es una ayuda o herramienta útil que podrá dar una predicción instantánea, para que el paciente obtenga una retroalimentación en el momento, conociendo la primera interpretación hecha por el algoritmo, y que no tenga que esperar 3 o más días hasta agendar una visita médica, con el fin de obtener información del estado en el que se encuentra. Destacando que la predicción está sujeta a la aprobación de un médico especialista.

El paciente no es el único beneficiado con esta investigación, sino que el personal presente de una institución de salud, ya que con estas predicciones se puede ordenar las listas de espera en base a la gravedad o estado de la enfermedad, permitiendo tomar decisiones con tiempo y de manera organizada.

5.1.1. Trabajo Futuro

Como trabajo futuro, se propone hacer hincapié en preprocesar de manera más exhaustiva el conjunto de imágenes de entrenamiento, más en concreto la calidad de las muestras a utilizar, la cantidad de muestras por clase. Por lo que se puede hacer uso de más de un conjunto de datos existente, con el fin reducir el error de predicción por clase.

Una segunda propuesta para la mejora de los valores obtenidos es el estudio si los filtros de imagen tales como la ecualización CLAHE, mencionada en esta investigación, poseen un mejor rendimiento que el entrenamiento por imágenes sin filtrar.

Una tercera propuesta para futuros trabajos, es la implementación de una aplicación de enfoque médico, donde una persona que posee su examen de fondo de retina, pueda cargar la imagen al sistema y que este entregue la predicción, junto a ciertas métricas. Para ello el trabajo debería tener como enfoque el desarrollo de software y todas las fases que comprende el desarrollo de software.

Apéndice A

Lista de Acrónimos

CNN - Convolutional Neural Network o Red Neuronal Convolucional

Dataset – Conjunto de datos

DL – Deep Learning o Aprendizaje profundo

TL – Transfer Learning o Transferencia de aprendizaje

SVM – Support Vector Machine o Máquinas de Soporte Vectorial

GWO – Grey Wolf Optimization

FC – Fully-Connected

CLAHE – Contrast-Limited Adaptative Histogram Equalization

FHD – Full High Definition

CONV – Capa Convolucional

RD – Retinopatía Diabética

RDNP – Retinopatía Diabética No Proliferante

RDP – Retinopatía Diabética Proliferante

VEGF – Vascular Endothelial Growth Factor

AAO - American Academy of Ophthalmology

IDF – Federación Internacional de Diabetes

OMS – Organización Mundial de la Salud

Bibliografía

- Cohen, M. F. (2011). *An introduction to logic and scientific method*. Read Books Ltd.
- Cree, M. J., Olson, J. A., McHardy, K. C., Sharp, P. F., and Forrester, J. V. (1997). A fully automated comparative microaneurysm digital detection system. *Eye*, 11(5):622–628.
- Fong, D. S., Aiello, L., Gardner, T. W., King, G. L., Blankenship, G., Cavallerano, J. D., Ferris, F. L., and Klein, R. (2004). Retinopathy in diabetes. *Diabetes care*, 27(suppl 1):s84–s87.
- Gadekallu, T. R., Khare, N., Bhattacharya, S., Singh, S., Maddikunta, P. K. R., and Srivastava, G. (2020). Deep neural networks to predict diabetic retinopathy. *J. Ambient Intell. Humaniz. Comput.*
- Guan, Q., Huang, Y., Zhong, Z., Zheng, Z., Zheng, L., and Yang, Y. (2018). Diagnose like a radiologist: Attention guided convolutional neural network for thorax disease classification. *arXiv preprint arXiv:1801.09927*.
- Huang, G., Liu, Z., Van Der Maaten, L., and Weinberger, K. Q. (2017). Densely connected convolutional networks. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 4700–4708.
- Klein, R., Klein, B. E., Moss, S. E., and Cruickshanks, K. J. (1994). The wisconsin epidemiologic study of diabetic retinopathy: Xiv. ten-year incidence and progression of diabetic retinopathy. *Archives of ophthalmology*, 112(9):1217–1228.
- LeCun, Y., Bengio, Y., and Hinton, G. (2015). Deep learning. *nature*, 521(7553):436–444.
- LeCun, Y., Boser, B. E., Denker, J. S., Henderson, D., Howard, R. E., Hubbard, W. E., and Jackel, L. D. (1990). Handwritten digit recognition with a back-

- propagation network. In *Advances in neural information processing systems*, pages 396–404.
- Mallat, S. (2016). Understanding deep convolutional networks. *Philosophical Transactions of the Royal Society A: Mathematical, Physical and Engineering Sciences*, 374(2065):20150203.
- Mellitus, D. (2005). Diagnosis and classification of diabetes mellitus. *Diabetes care*, 28(S37):S5–S10.
- Meyer, A. N., Payne, V. L., Meeks, D. W., Rao, R., and Singh, H. (2013). Physicians' diagnostic accuracy, confidence, and resource requests: a vignette study. *JAMA internal medicine*, 173(21):1952–1958.
- MINSAL (2010). Guia clinica de retinopatia diabetica.
- O’Shea, K. and Nash, R. (2015). An introduction to convolutional neural networks. *arXiv preprint arXiv:1511.08458*.
- Pizer, S. M. (1990). Contrast-limited adaptive histogram equalization: Speed and effectiveness stephen m. pizer, r. eugene johnston, james p. ericksen, bonnie c. yankaskas, keith e. muller medical image display research group. In *Proceedings of the First Conference on Visualization in Biomedical Computing, Atlanta, Georgia, May 22-25, 1990*, page 337. IEEE Computer Society Press.
- Rosas-Romero, R., Martínez-Carballido, J., Hernández-Capistrán, J., and Uribe-Valencia, L. J. (2015). A method to assist in the diagnosis of early diabetic retinopathy: Image processing applied to detection of microaneurysms in fundus images. *Computerized medical imaging and graphics*, 44:41–53.
- Torrey, L. and Shavlik, J. (2010). Transfer learning. In *Handbook of research on machine learning applications and trends: algorithms, methods, and techniques*, pages 242–264. IGI global.
- Van Dyk, D. A. and Meng, X.-L. (2001). The art of data augmentation. *Journal of Computational and Graphical Statistics*, 10(1):1–50.
- Wu, J. (2017). Introduction to convolutional neural networks. *National Key Lab for Novel Software Technology. Nanjing University. China*, 5:23.
- Xiao, Z., Zhang, X., Geng, L., Zhang, F., Wu, J., Tong, J., Ogunbona, P. O., and Shan, C. (2017). Automatic non-proliferative diabetic retinopathy screening system based on color fundus image. *Biomedical engineering online*, 16(1):122.

